혈구 자동 검출·계수 프로젝트 총괄 정리

Oct 16, 2026 · @김규리

1. 프로젝트 개요

비염색 혈액 현미경 영상을 **가상 염색**으로 염색 영상처럼 바꾼 뒤, 실제 염색 영상으로 학습한 검출·계수 모델로 RBC·WBC를 자동 계수한다. 이 파이프라인이 본 프로젝트의 메인이며, 비염색 영상을 직접 학습하는 방식은 다루지 않는다.

- **주제:** 혈액 현미경 영상 기반 적혈구(RBC)·백혈구(WBC) 자동 검출 및 계수 시스템
- **문제:** 비염색 영상은 세포가 거의 투명해 검출 정확도가 낮고(선행연구 비염색 WBC 약 65% vs 염색 약 95%), 라벨 있는 비염색 데이터도 거의 없다.
- **해결 방향:** 비염색 → 가상 염색 → 염색 영상용 검출 모델. 검출 모델은 라벨이 풍부한 실제 염색 데이터로, 가상 염색 모델은 라벨 없는 비염색·염색 영상으로 학습한다.
- **최종 산출물:** 웹 기반 검사 보조 시스템(비염색 영상 업로드 → 가상 염색 결과 + 검출 결과 + RBC·WBC 개수 표시)

현재 의료 현장

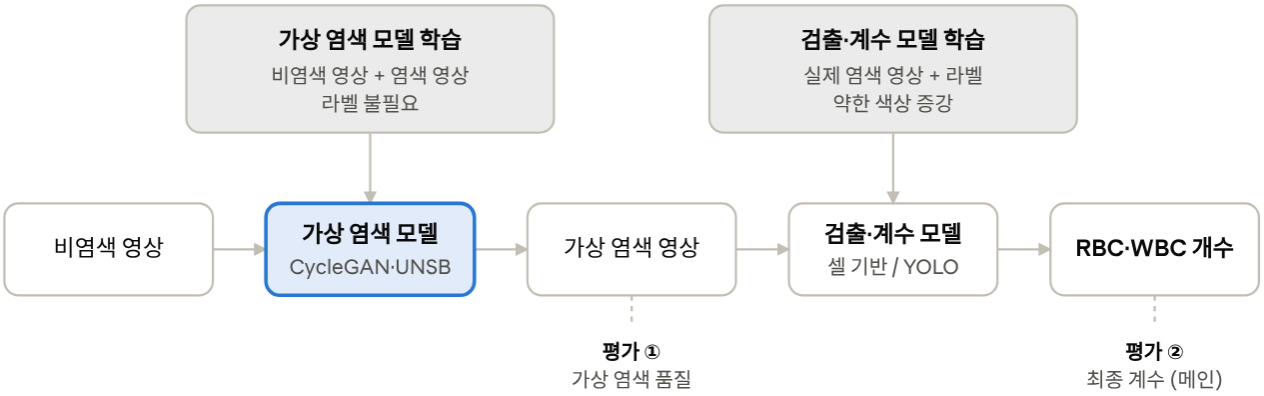
1. 병원은 자동 혈구 분석기로 1차 CBC 계수를 한다. 세포를 영상으로 보지 않고 전기저항·레이저 산란·형광 신호로 개수와 종류를 판별한다.
2. 신호가 비정상인 샘플(약 10~25%)은 분석기가 분류를 확정하지 못하고 플래그만 띄운다.
3. 이 샘플은 도말 → 고정 → 염색 → 헹굼 → 건조 후 사람이 현미경으로 판독한다.
4. 수동 염색은 슬라이드당 약 40~45분, 자동 염색기는 약 5~7분이 걸리고, 검사자 숙련도에 따라 결과 편차가 생긴다.
5. 분석기와 자동 염색기는 장비가 비싸고 시약비가 계속 들어 소규모 의료기관·저자원 환경에서는 도입이 어렵다.

본 프로젝트는 자동 분석기를 대체하지 않는다. 그 뒤 단계인 **도말 영상 판독을 염색 없이 보조**하는 것이 포지션이다.

2. 전체 파이프라인

추론은 비염색 영상 → 가상 염색 → 검출·계수 한 줄이고, 그 안의 두 모델은 각자 따로 학습한다.

비염색 영상은 가상 염색을 거쳐 염색 영상으로 학습한 검출 모델에 들어간다



전체 파이프라인 · 학습 2개, 추론 5단계, 평가 2지점

검출 모델은 실제 염색 영상만 보고 학습하고, 비염색 영상은 가상 염색 모델을 거쳐서만 들어간다. 평가 0(검출 모델 자체)은 실제 염색 테스트 영상으로 따로 한다.

3. 학습 체계

모델 두 개를 **따로** 학습한다. 검출·계수 모델은 라벨 있는 실제 염색 영상으로, 가상 염색 모델은 라벨 없는 비염색·염색 영상으로 학습한다. 비염색 라벨은 학습에 필요하지 않다.

3-1. 검출·계수 모델 학습

1. **데이터:** TXL-PBC 실제 염색 영상 + RBC·WBC 라벨을 학습/검증/테스트로 분할
2. **전처리:** 세포 크기 기준으로 배율 맞추기(리사이즈), 입력 크기 통일
3. **증강:**
   - 일반 증강: 뒤집기, 회전, 크기 변화
   - 약한 색상 증강(색조·채도·밝기 조금씩): 가상 염색 결과는 실제 염색과 색 톤이 완전히 같지 않아, 그 차이에 버티도록 하기 위함
4. **모델:** 7장의 후보(셀 기반 Cellpose 계열 + 분류 / 박스 기반 YOLO) 중 선택
5. **완료 기준:** 실제 염색 테스트셋에서 성능 확인 (평가 0)

3-2. 가상 염색 모델 학습

1. **데이터 (짝 없음, 현재):**
   - 비염색 도메인: RedTell 비염색 영상 중 학습 분할
   - 염색 도메인: TXL-PBC 염색 영상 (라벨은 쓰지 않고 영상만)
2. **데이터 (짝 확보 시):** IEEE Dataport·Lina et al. 비염색-염색 짝 중 학습 분할

3. **전처리:** 비염색·염색 영상의 세포 크기가 비슷하도록 리사이즈, 패치 단위(예: 256×256)로 자르기, 밝기 정규화
4. **모델:** 짝 없음 → CycleGAN(기준선), UNSB(메인) / 짝 있음 → pix2pix, BBDM 추가 (6장)
5. **완료 기준:** 가상 염색 품질 확인 (평가 ①)

3-3. (선택) 가상 염색 영상으로 미세조정

1. 라벨 있는 비염색 영상(RedTell 학습 분할, RBC)을 가상 염색한다
2. 세포 위치는 그대로이므로 **원본 라벨을 그대로** 붙인다
3. 실제 염색 데이터와 섞어 검출 모델을 미세조정한다

- 가상 염색 영상을 보고 새로 라벨링하지 않는다 (GAN이 핵을 잘못 그리면 라벨도 틀려짐).
- 현재는 RBC 79장뿐이라 규모가 작다. 짝 데이터를 받으면 WBC까지 확장한다.

3-4. 데이터 분할

데이터	검출 모델 학습	가상 염색 모델 학습	평가
TXL-PBC 학습·검증 분할 (염색)	사용 (라벨 포함)	사용 (영상만)	—
TXL-PBC 테스트 분할 (염색)	—	—	평가 0
BCCD·BCDD (염색, 출처 다름)	—	—	평가 0 (교차 출처)
RedTell 학습 분할 (비염색 RBC)	선택 (3-3 미세조정)	사용 (비염색 도메인)	—
RedTell 평가 분할 (비염색 RBC)	—	—	평가 ①②
짝 데이터 학습 분할 (확보 시)	선택	사용 (pix2pix·BBDM)	—
짝 데이터 평가 분할 (확보 시)	—	—	평가 ①② (RBC·WBC)

- BCCD·BCDD 영상은 TXL-PBC에 포함돼 있어, 출처 단위로 분리해야 학습·평가가 겹치지 않는다.
- 가능하면 같은 슬라이드·환자의 영상이 학습과 평가에 나뉘지 않게 슬라이드 단위로 분할한다.

4. 평가 체계

평가는 세 단계다. **평가 ② 최종 계수 성능이 메인**이고, 평가 0과 ①은 성능이 어느 단계에서 떨어지는지 찾기 위한 것이다. 정답은 항상 실제 영상 기준이다.

4-1. 평가 0: 검출·계수 모델 자체

1. **입력:** 실제 염색 테스트 영상 (TXL-PBC 테스트 분할, 출처가 다른 BCCD·BCDD)
2. **지표:** 이미지당 개수 오차(MAE), 검출 정확도(박스 기반 mAP@0.5 / 셀 기반 매칭 F1)
3. **의미:** 파이프라인의 상한. 가상 염색이 완벽해도 이 수치를 넘기 어렵다

4-2. 평가 ①: 가상 염색 품질

1. **짝 데이터 있을 때:** 가상 염색 영상과 같은 위치의 실제 염색 영상 비교 → SSIM, PSNR, LPIPS
2. **짝 데이터 없을 때 (현재):**
   - FID: 가상 염색 영상들이 실제 염색 영상들과 분포가 얼마나 비슷한지
   - 세포 수 보존: 비염색 원본과 가상 염색 결과에 같은 세포 분할 모델을 돌려 세포 수·위치가 유지되는지 확인 (정답 없이 구조 보존 확인 가능)
   - 육안 확인: 없는 핵이 생기거나 있는 세포가 사라지는지(hallucination)
3. **비교:** CycleGAN vs UNSB (짝 있으면 pix2pix, BBDM 추가)

4-3. 평가 ②: 최종 계수 성능 (메인)

1. **입력:** 정답 있는 실제 비염색 테스트 영상 → 가상 염색 → 검출·계수 모델
   - 현재: RedTell 평가 분할 (RBC)
   - 짝 데이터 확보 시: 짝 데이터 평가 분할 (RBC·WBC, 정답은 실제 염색 짝에서 옮기고 육안 검수)
2. **지표:** 이미지당 개수 오차(MAE, 메인), 검출 정확도, 이미지당 처리 시간(가상 염색 포함)
3. **비교 대상:**
   - 하한: 가상 염색 없이 비염색을 그대로 검출 모델에 입력 (학습이 아니라 측정만)
   - CycleGAN 가상 염색 → 검출 모델
   - UNSB 가상 염색 → 검출 모델
   - (선택) 3-3 미세조정 모델
   - 상한 (짝 데이터 있을 때): 같은 위치의 실제 염색 영상 → 검출 모델

4-4. 결과 비교표 (실험 후 채움)

방법	평가 ① 가상 염색 품질	평가 ② RBC MAE	평가 ② WBC MAE (짝 확보 시)	처리 시간
가상 염색 없음 (하한)	—			
CycleGAN				
UNSB				

방법	평가 ① 가상 염색 품질	평가 ② RBC MAE	평가 ② WBC MAE (짝 확보 시)	처리 시간
실제 염색 (상한)	—			

4-5. 지킬 것

- 정답은 원본(비염색 원본 라벨 또는 실제 염색 짝)에서만 가져온다. 가상 염색 영상에 라벨링하지 않는다.
- 가상 염색 모델 학습에 쓴 비염색 영상은 평가에 쓰지 않는다.
- RedTell은 저배율이라 평가 전 세포 크기를 TXL-PBC에 맞춰 리사이즈한다.
- 한 시야의 개수는 병원 CBC의 μL당 농도와 단위가 다르다. 도말 판독 보조 목적임을 명시한다.

5. 관련 선행연구 (혈구 비염색 검출·가상 염색)

혈구 가상 염색 연구는 2022년 GAN(pix2pix, cGAN) 단계에 머물러 있고, diffusion 계열 적용 사례는 찾지 못했다. 대부분 짝 데이터와 특수 영상(UV, 위상)을 쓴다.

연구	연도	입력 영상	방법	논문 보고 성능	코드·데이터
Hunt et al., Frontiers in Bioinformatics	2026	비염색 명시야 (미세유체)	YOLOv4로 WBC 검출 → YOLOv4로 활성화 분류 (가상 염색 없음)	F1: 림프구 약 80%, 활성 호중구 약 92%, 단핵구 전용 모델 약 97%	GitHub
Chen et al., Biomedical Optics Express	2022	비염색 도말, 일반 명시야 + 415 nm LED + 디포커스	pix2pix 가상 Wright-Giemsa 염색 + YOLOv5 WBC 5종 분류	분류 F1 0.986, mAP 0.980 / 가상 염색 SSIM 0.67~0.77 / 검출 9 ms, 가상 염색 4.5 ms (512×512 패치)	논문 참고문헌 55에 있다고 명시
Kaza et al., BME Frontiers	2022	비염색 도말, deep-UV 260 nm	cGAN(U-Net 생성기, Lab 색공간) 가상 Giemsa + U-Net 분할 + ResNet-18 분류	MS-SSIM 0.9125 / 세포 Dice 0.9899, 핵 Dice 0.9718 / 5종 분류 94.02%	코드 없음, 데이터 OSF
Fanous et al., Scientific Reports	2022	비염색 도말, 정량 위상 영상 (cSLIM)	pix2pix 가상 Wright 염색 + EfficientDet-D0 검출 + U-Net 분할	정밀도: 호산구 90.09%, 림프구 56.6% / 분할 F1 68.5~86.7% / 분류 약 140 ms/프레임	공개 없음
Lina et al., IJCS	2021	비염색·염색 짝 도말	변형 watershed(고전 영상처리), VGG16·YOLOv3 비교	WBC 검출: 비염색 약 65.7%, 염색 94.82% / 림프구 17.65% / 약 0.5초/장	공개 없음 (저자 메일 요청 중)

- **문제 근거:** Lina et al.에서 비염색 WBC 검출은 염색 대비 약 30%p 낮고, 림프구는 RBC와 크기가 비슷해 가장 어렵다.
- **가장 가까운 연구:** Chen et al.은 일반 현미경 기반 + 가상 염색 + YOLO라는 구조가 Plan C와 같다. 다만 짝 데이터 3,970쌍을 직접 촬영했다.
- **차별점:** 본 프로젝트는 짝 데이터 없이(unpaired) 최신 diffusion 계열 변환을 혈구에 적용한다.
- 수치 주의: Lina et al.은 초록(65.42%)과 표(65.7%)의 값이 다르다. 인용은 표 값 기준으로 한다.

6. 가상 염색 모델 후보 (비염색 → 염색)

메인은 **UNSB**, 기준선은 **CycleGAN**이다. 둘 다 짝 데이터 없이 학습되고 코드가 공개돼 있다. 가상 염색도 학습된 모델이라, 비염색 영상과 염색 영상을 보여주며 변환을 직접 학습시켜야 한다.

6-1. 짝 데이터 없이 가능 (unpaired) — 현재 상황에 적용

방법	연도·학회	방법 요약	논문 보고 성능	코드	역할
CycleGAN	2017, ICCV	생성기 2개(A→B, B→A) + 판별기 2개. A→B→A로 되돌렸을 때 원본과 같아야 한다는 순환 일관성 손실로 학습	UNSB 논문 기준 FID: Horse2Zebra 77.2, Summer2Winter 84.9	GitHub	기준선
UNSB (Unpaired Neural Schrödinger Bridge)	2024, ICLR (KAIST)	비염색→염색 변환을 여러 단계(기본 5단계)로 나눠 조금씩 이동. 각 단계는 적대적 학습 + CUT의 패치 대조 손실로 입력 구조를 유지	FID: Horse2Zebra 35.7, Summer2Winter 73.9 (CycleGAN 대비 전 벤치마크 우수) / 0.045 s/장	GitHub	메인 기법
Score-based Diffusion for Unpaired Virtual Histology Staining	2025, arXiv	점수 기반 diffusion + 상호정보 기반 에너지 함수로 구조와 염색 특성 분리, 세포 단위 대조 학습 (조직 H&E→IHC)	초록에 수치 없음	미공개 (게재 후 공개 예정)	최신 동향 참고

6-2. 짝 데이터 필요 (paired) — IEEE·Lina 짝 데이터 확보 시 추가

방법	연도·학회	방법 요약	논문 보고 성능	코드	역할
pix2pix	2017, CVPR	조건부 GAN(U-Net 생성기 + PatchGAN 판별기) + L1 손실	혈구 적용 사례: Chen et al. 2022 SSIM 0.67~0.77, 4.5 ms/패치	GitHub	짝 데이터 기준선

방법	연도·학회	방법 요약	논문 보고 성능	코드	역할
BBDM (Brownian Bridge Diffusion)	2023, CVPR	VQGAN 잠재 공간에서 입력 영상 → 목표 영상으로 이어지는 브라운 브리지 diffusion. 추론 기본 200단계	FID: edges2shoes 10.9 (pix2pix 36.3), CelebAMask-HQ 21.4 (pix2pix 57.0)	GitHub	diffusion 기법
BBDM 가상 염색 (Zhang et al., Nature Communications)	2025 (UCLA Ozcan 그룹)	비염색 자가형광 조직 → 가상 H&E + 해상도 1~5배 향상. 1,000단계, mean/skip 샘플링으로 분산 감소	cGAN 대비 SSIM·LPIPS·PSNR 우수 (2~5배), 병리의 판독 일치	Zenodo	diffusion 가상 염색 근거
HistDiT	2026, arXiv	Latent Diffusion Transformer + 병리 foundation model(UNI2) 임베딩 (조직 H&E→IHC)	BCI FID 49.15 (CycleGAN·pix2pix 160~188)	미공개	최신 동향 참고

6-3. 적용 계획

1. CycleGAN으로 비염색→염색 변환을 먼저 학습해 기준선을 만든다.
2. UNSB를 같은 데이터로 학습해 검출 성능·처리 시간을 비교한다.
3. 짝 데이터를 확보하면 pix2pix, BBDM을 추가한다.

- 위 FID는 일반 영상 벤치마크의 저자 보고값이다. 혈구 영상에서도 같은 순서가 나오는지는 본 프로젝트에서 확인해야 한다.
- diffusion 계열은 GAN보다 느리다(UNSB 0.045 s vs CUT 0.0033 s). 처리 시간을 평가 항목에 넣는다.
- 비염색 RBC 데이터(RedTell)에는 WBC가 없어, 짝 데이터 없이는 RBC 변환만 의미가 있다.
- GAN·diffusion 모두 없는 핵을 그리거나 지울 수 있어(hallucination) 변환 결과를 육안으로 확인한다.

7. 검출·계수 모델 후보

검출 모델은 아직 확정하지 않는다. 교수님은 셀 기반(세포 분할) 모델을 추천했다. 크게 박스 기반 검출(YOLO)과 셀 기반 분할(Cellpose, StarDist) 두 방식이 있다.

7-1. 모델별 특징

모델	연도·출처	방식	출력	보고 성능	코드
YOLO26	2026.1, Ultralytics	박스 기반 단일 단계 검출. NMS 없는 추론 선택 가능, 작고 빽빽한 객체용 손실	세포별 박스 + 클래스 (분할 모델도 있음)	COCO mAP50-95: n 40.9 / s 48.6 / m 53.1	GitHub
YOLOv8s (TXL-PBC 기준선)	2025, Scientific Data	박스 기반 검출	RBC·WBC·혈소판 박스	염색 혈구 mAP50 0.978, mAP50-95 0.864	GitHub
Cellpose	2021, Nature Methods	셀 기반 분할. 각 픽셀에서 세포 중심으로 향하는 흐름을 예측해 세포를 하나씩 분리	세포별 픽셀 마스크 (클래스 없음)	혈구 보고값 없음	GitHub
Cellpose-SAM	2025, bioRxiv	Cellpose + SAM 인코더. 처음 보는 영상에 일반화	세포별 픽셀 마스크	혈구 보고값 없음	GitHub
StarDist	2018, MICCAI	셀 기반 분할. 세포를 별 모양 다각형으로 표현	세포별 다각형 마스크	혈구 보고값 없음	GitHub

7-2. 장단점

모델	장점	단점
YOLO 계열	한 모델에서 검출 + RBC/WBC 분류까지 끝남 / 빠름 / 혈구 선행연구(Chen et al., TXL-PBC)가 많아 비교 쉬움	라벨 있는 데이터로 학습 필수 / 붙거나 겹친 RBC는 박스가 겹쳐 빠지거나 합쳐지기 쉬움 → 계수 오차 / 세포 모양 정보 없음
Cellpose	붙은 세포 분리에 강함 → 계수에 유리 / 미리 학습돼 있어 추가 학습 없이도 사용, 적은 장수로 미세조정 가능 → 라벨 부족에 유리 / 세포 면적·모양 정보	RBC/WBC 분류를 하지 않아 분류 단계가 따로 필요 / YOLO보다 느림
Cellpose-SAM	Cellpose 장점 + 처음 보는 영상(비염색, 가상 염색)에 더 잘 일반화	모델이 커서 더 느리고 GPU 메모리 필요 / 분류 단계 별도
StarDist	둥근 세포(RBC)에 잘 맞고 가벼움	불규칙한 모양(분엽 핵 WBC 등)에 약함 / 분류 단계 별도

7-3. 방식별 파이프라인

1. **박스 기반:** 입력 영상 → YOLO → RBC·WBC 박스 → 개수
2. **셀 기반:** 입력 영상 → Cellpose 등으로 세포 분할 → 세포별 RBC/WBC 분류 (크기·핵 색 기준 또는 작은 분류 모델) → 개수

- 셀 기반에서는 가상 염색이 특히 분류 단계에 도움이 된다. WBC 핵이 보라색으로 나오기 때문이다.
- 두 방식을 모두 돌려 계수 오차를 비교하는 것도 가능하다.
- Cellpose-SAM의 속도·메모리는 논문에서 직접 확인하지 못했다. 사용 전 확인이 필요하다.

8. 데이터셋

염색 데이터는 충분하고, 라벨 있는 실제 비염색 데이터는 RBC만 확보됐다. 실제 비염색 WBC·짝 데이터는 아직 없다.

데이터셋	염색	라벨	규모	용도	상태
TXL-PBC	염색	RBC·WBC·혈소판 bbox (YOLO)	1,260장, 박스 18,143개	메인 학습, 염색 테스트, 시뮬레이션 비염색 생성	바로 다운로드
BCCD	염색	RBC·WBC·혈소판 bbox (VOC)	364장	출처별 교차 평가	바로 다운로드 (RBC 라벨 누락 다수)
BCDD	염색	RBC·WBC bbox (CSV)	100장	출처별 교차 평가 (염색 톤 다름)	바로 다운로드
RedTell	비염색 (명시야)	SDE 서브셋 RBC instance mask	79장	실제 비염색 RBC 평가, GAN 비염색 도메인	바로 다운로드 (WBC 없음, 저배율)
Kaza et al. deep-UV	비염색 UV + 가상 Giemsa 짝	WBC 분할·분류	약 74,000쌍	참고 (UV라 일반 명시야와 도메인 다름)	OSF 공개, 내용 확인 필요
Blood Smear Virtual Staining Dataset	비염색·염색 짝	미확인	미확인	실제 비염색 RBC·WBC 평가 (최우선)	IEEE Dataport 구독 또는 저자 메일 필요
Lina et al. 2021 데이터	비염색·염색 짝	WBC 5종	비염색 458장, 염색 722장	실제 비염색 WBC 평가	10/4 요청 메일, 회신 없음

- IEEE Dataport는 IEEE Xplore와 별개 구독이다. IEEE Society 회원은 무료, 개인 구독은 월 $40 (구독 안내).
- 학교 도서관 학술 DB 목록은 로그인 후 확인해야 한다.

9. 리스크와 할 일

가장 큰 리스크는 실제 비염색 WBC 정답 데이터가 없다는 점이다. 짝 데이터를 못 구해도 실제 비염색 RBC 평가로 정량 결과는 나온다.

리스크	영향	대응
비염색 WBC·짝 데이터 미확보	실제 비염색 WBC 평가 불가	실제 비염색 RBC로 평가, WBC는 한계로 명시 / 자체 촬영(염색 전후 같은 위치) 검토
GAN·UNSB 학습 불안정, hallucination	가상 염색 결과 신뢰도 저하	육안 확인, CycleGAN 결과를 먼저 확보하고 UNSB는 추가
diffusion 계열 학습·추론 시간	일정 지연	CycleGAN 먼저, UNSB는 그다음
RedTell 배율·도메인 차이	비염색 RBC 평가 성능 전반 저하	리사이즈로 세포 크기 맞추기, Methods에서 μm/pixel 확인

할 일

- [ ] Lina 교수 리마인드 메일 (가능하면 지도교수 CC)
- [ ] IEEE Dataport 저자(Maham Nayab) 메일 (공개 이메일 없음 → Dataport 페이지의 'Send Author a Private Message'로 보내기)
- [ ] 도서관 로그인 후 IEEE Dataport 기관 구독 여부 확인 (없으면 Society 회원 가입 검토)
- [ ] 교수님께 자체 촬영 가능 여부, 언급하신 Nature 혈구 가상 염색 논문 제목 여쭤보기
- [ ] Kaza et al. OSF 데이터 내용 확인
- [ ] 검출 모델 확정 (박스 기반 vs 셀 기반) 후 TXL-PBC로 검출·계수 모델 학습
- [ ] RedTell mask → bbox 변환, 배율 확인
- [ ] Merino et al. 2026 원문 확인 (비염색 내용 유무)